# 数据库系统原理

教程：数据库系统概论（第5版）

结合：CMU 15-445/645 INTRO TO DATABASE SYSTEMS

华中科技大学 计算机学院

左琼

# 第九章 关系查询处理及查询优化

*Principles of Database Systems*

# 第九章 关系查询处理及查询优化

# 9.1 关系数据库系统的查询处理

## 9.1.1 查询处理步骤

1. 查询分析
2. 查询检查
3. 查询优化
4. 查询执行

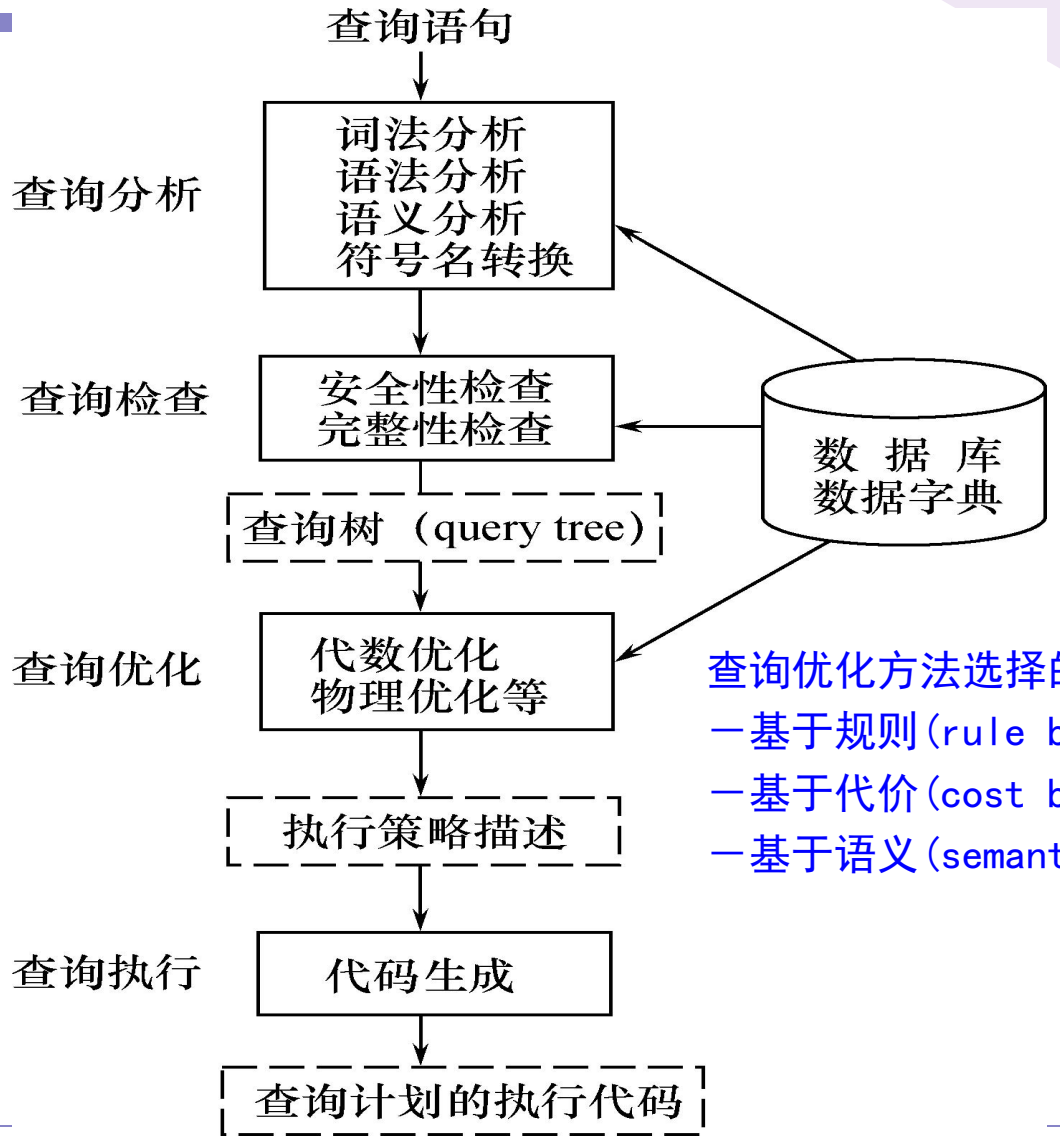


查询优化方法选择的依据：

- 基于规则(rule based)
- 基于代价(cost based)
- 基于语义(semantic based)

# 关系数据库系统的查询处理流程

- 查询计划：
  - 操作算子以树的形式进行组织
  - 数据流从叶子结点流向根节点
  - 根节点的输出是查询的结果

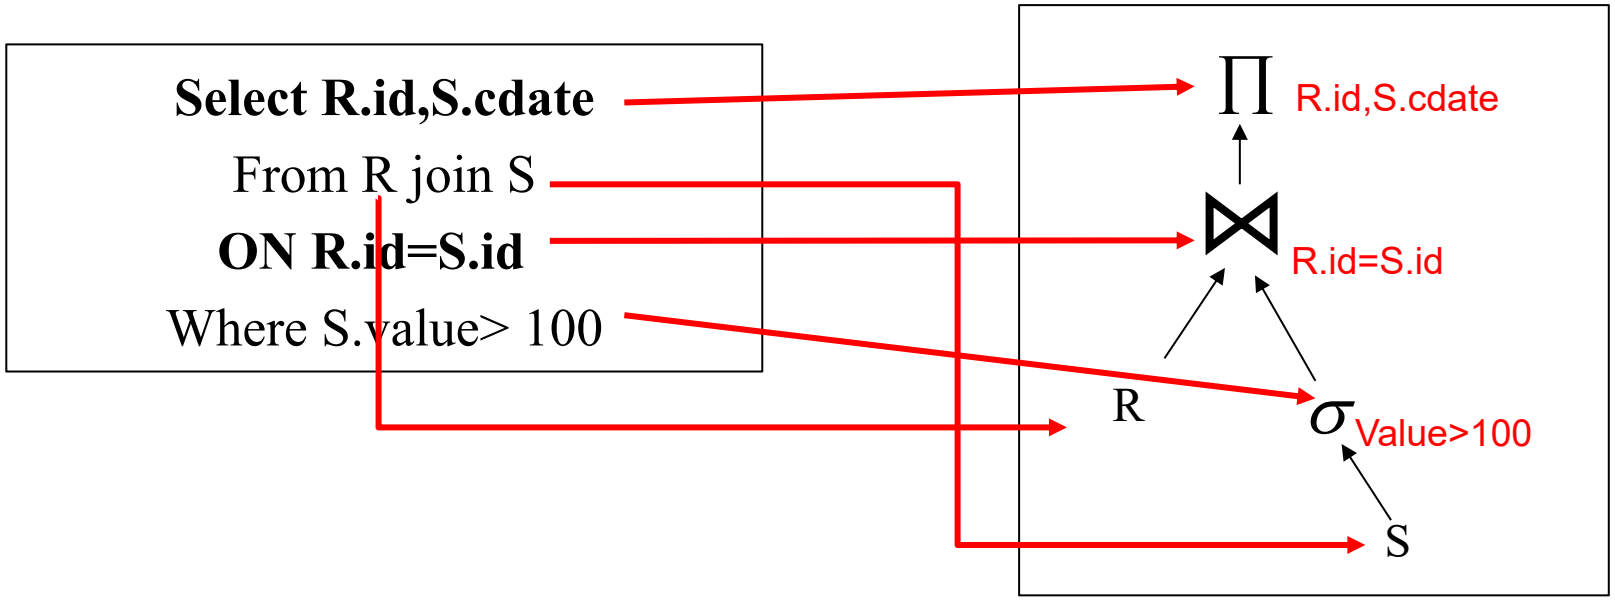

# 9.1.2 查询处理模型

- 处理模型定义系统如何执行一个查询计划，不同的任务负载对应不同的权衡结果。
  - 迭代模型（Iterator Model）
  - 物化模型（Materialization Model）
  - 向量 / 批量模型（ Vectorized / Batch Model ）

# 1. 迭代模型

- 迭代模型(Iteration Model)：每个查询计划的算子执行一个Next函数。
  - 也称作火山模型（Volcano Model）/流水线模型（Pipeline Model）。
  - 该计算模型将关系代数中每一种操作抽象为一个 Operator，将整个 SQL 构建成一个 Operator 树，查询树自顶向下的调用next()接口，数据则自底向上的被拉取处理。
  - 每次调用Next得到一个元组，或者一个空值标记（null marker）。
  - 算子通过循环调用它的子节点的Next函数用于获取元组进行，当处理完成后再通过Next函数获取下一个元处理组进行处理，直到得到一个NULL Marker。
  - 获取磁盘数据代价太大，需要它在内存中做足够多的操作。

# 1. 迭代模型

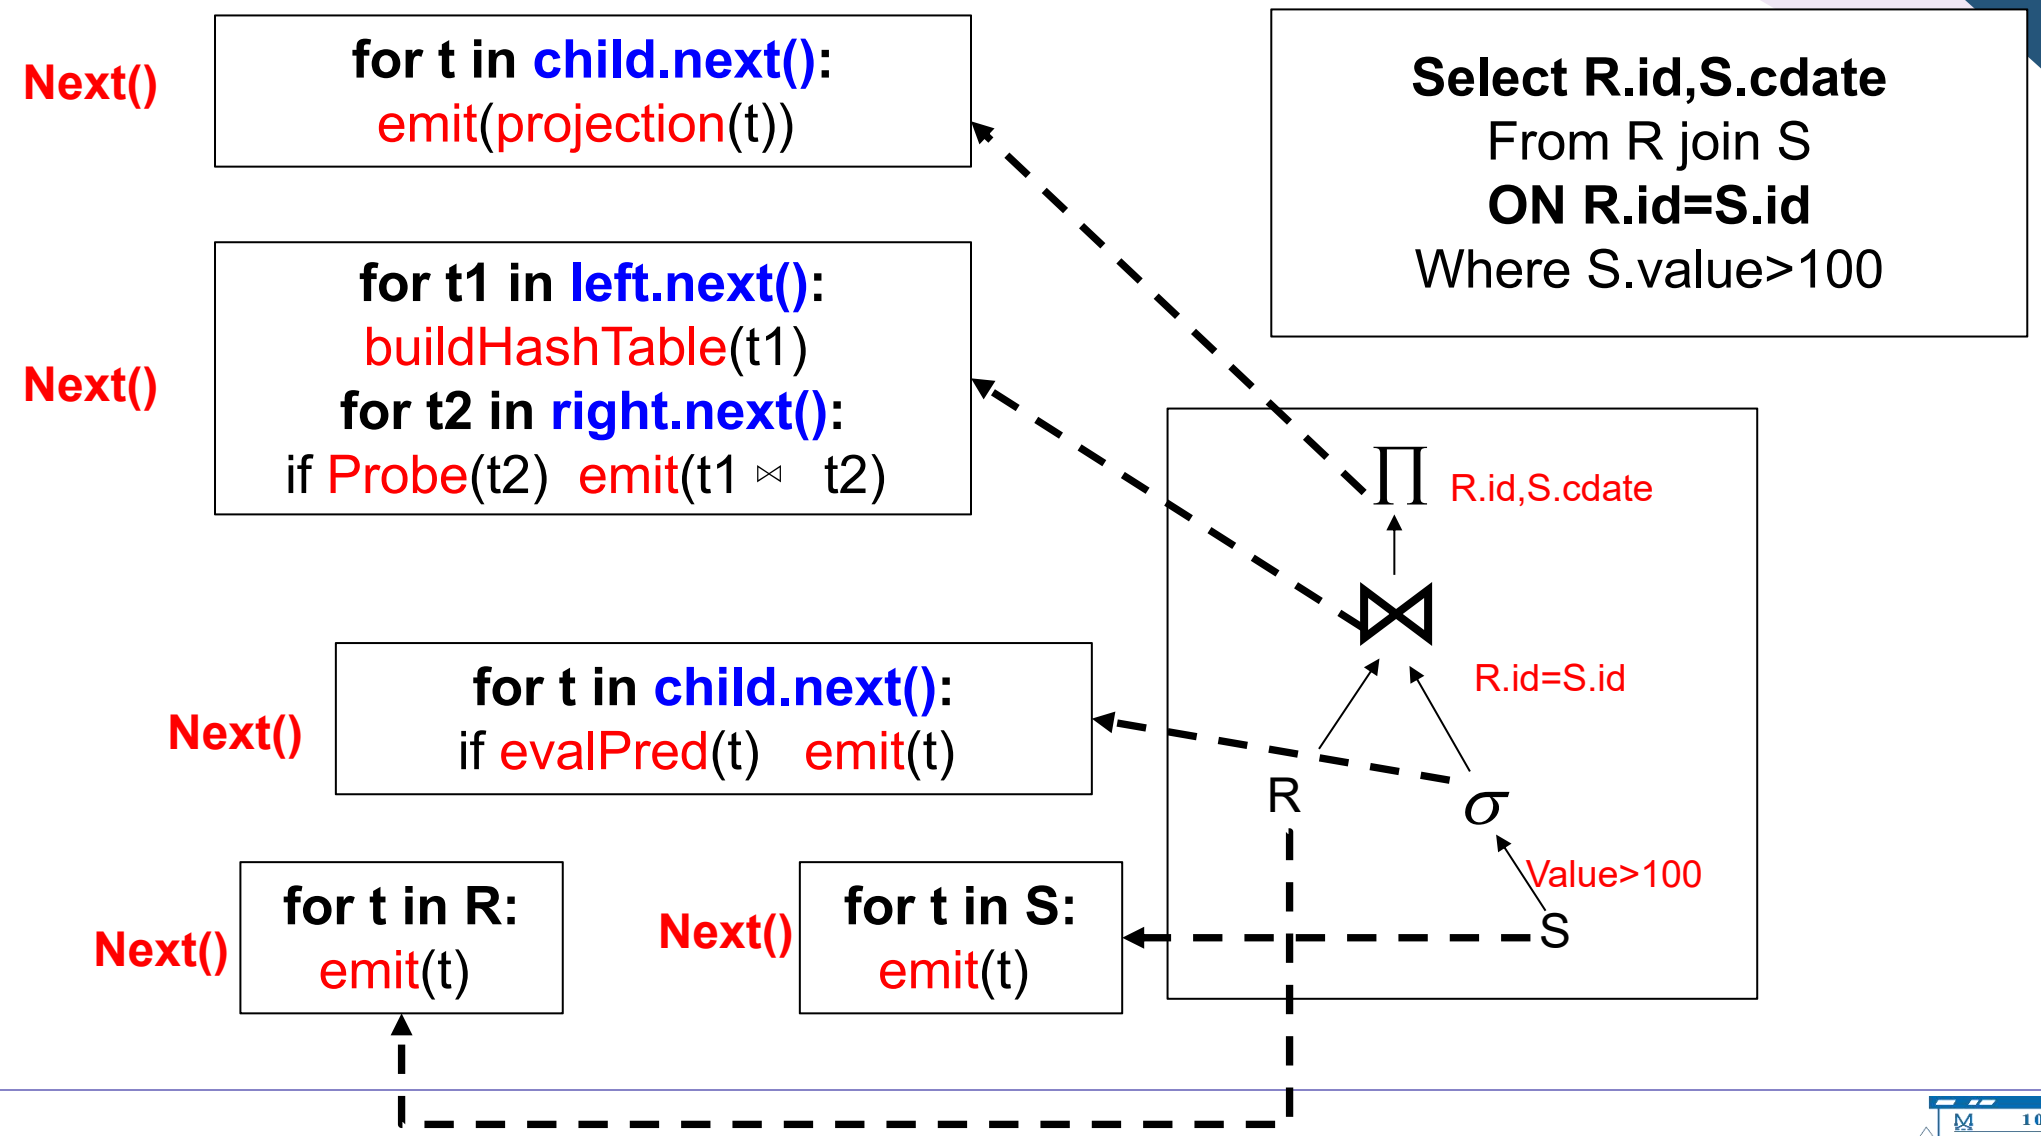
Next()
for t in child.next():
emit(projection(t))
Select R.id,S.cdate
From R join S
ON R.id=S.id
Where S.value>100
Next()
for t1 in left.next():
buildHashTable(t1)
for t2 in right.next():
if Probe(t2) emit(t1 ⋈ t2)
∏ R.id,S.cdate
⋈ R.id=S.id
Next()
for t in child.next():
if evalPred(t) emit(t)
R
σ Value>100
S
Next()
for t in R:
emit(t)
Next()
for t in S:
emit(t)

# 1. 迭代模型

1

```
for t in child.next():
    emit(projection(t))
```

2

```
for t1 in left.next():
    buildHashTable(t1)
    for t2 in right.next():
        if Probe(t2) emit(t1 ⋈ t2)
```

```
for t in child.next():
    if evalPred(t) emit(t)
```

单一元组

3

```
for t in R:
    emit(t)
```

```
for t in S:
    emit(t)
```

```
Select R.id,S.cdate
From R join S
ON R.id=S.id
Where S.value>100
```

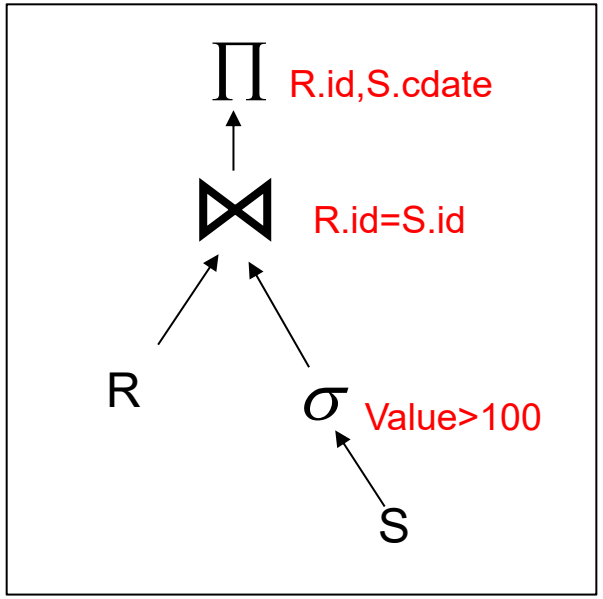

# 1. 迭代模型

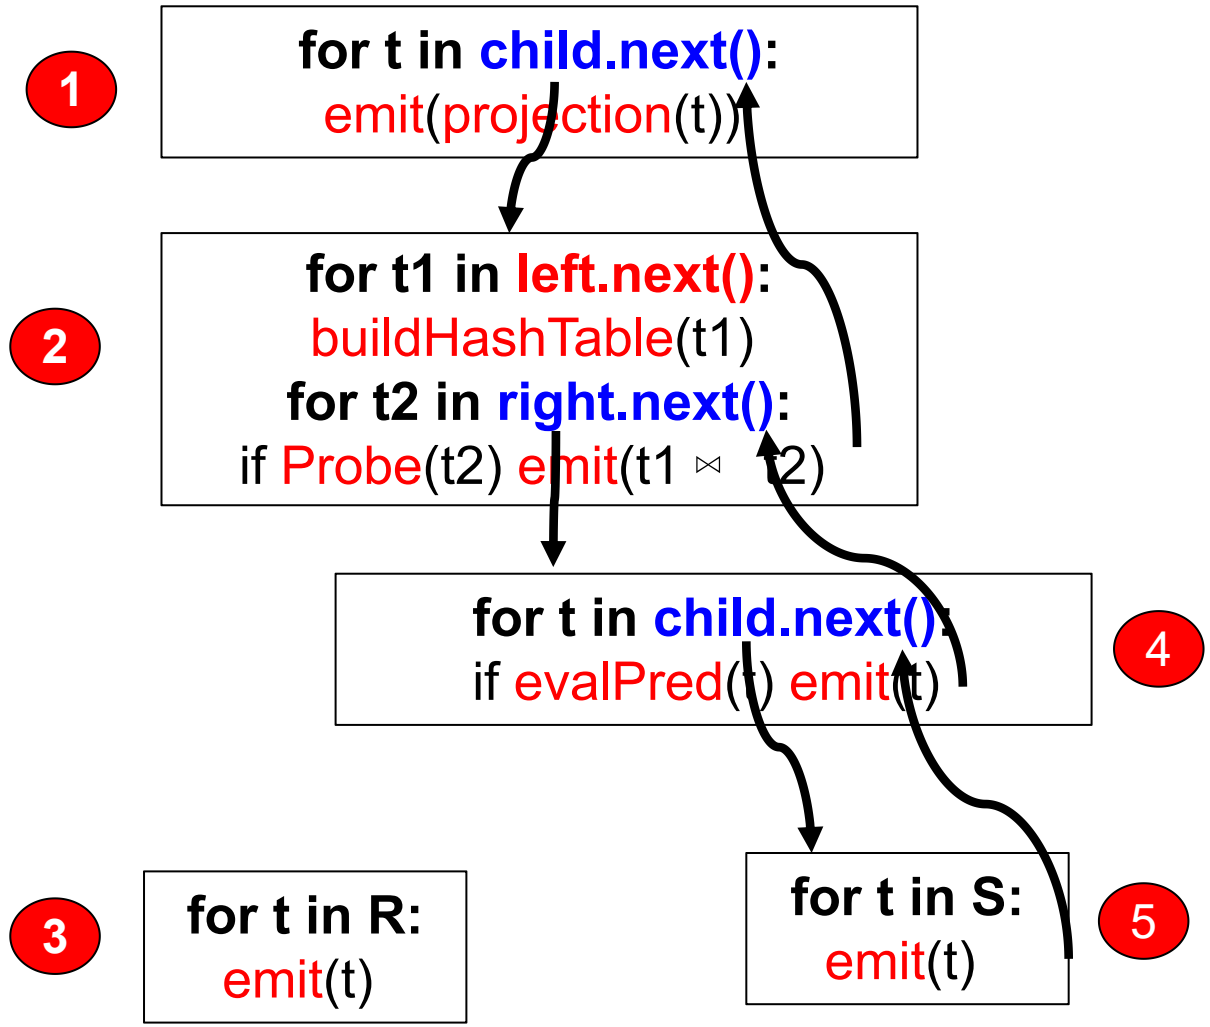


```
Select R.id,S.cdate
From R join S
ON R.id=S.id
Where S.value>100
```

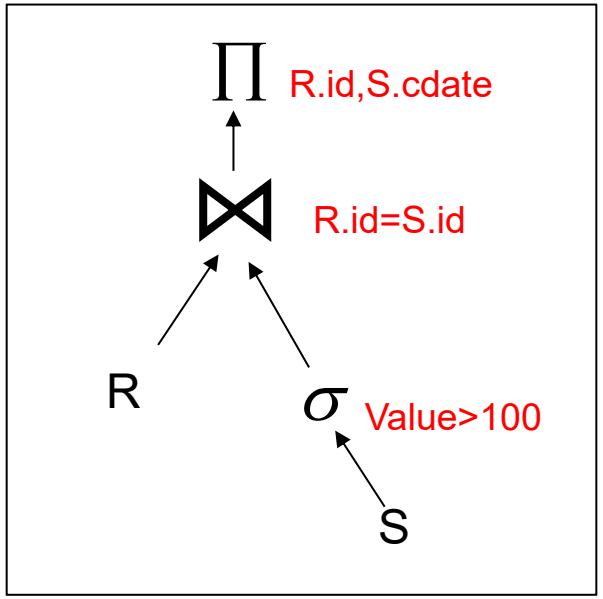

# 1. 迭代模型

- 迭代模型特点：
  - 几乎所有的DBMS都采用该模型，允许元组流水线。
  - 流水线带来的好处是：

    (1) 消除读和写临时关系的代价，从而减少查询计算代价。

    (2) 流水线产生查询结果，边生成边输出给用户，提高响应时间。很容易的控制输出，如limit操作。
  - 有些算子会阻塞数据的流动，直到其子节点发送所有的元组，例如join操作，子查询操作，排序操作。

*大多数关系型数据库都是使用迭代模型的，如 SQLite、MongoDB、Impala、DB2、SQLServer、Greenplum、PostgreSQL、Oracle、MySQL 等。*

# 2. 物化模型

- 物化模型（Materation Model）：
  - 算子一次性获取它所有的输入，当处理完成后再返回给它的父节点。
  - 算子能“物化”其输出作为一整个结果。
  - 为了避免下层算子返回的数据量过大，上层算子可以尽可能提供多的过滤条件。DBMS会将一些参数传递到操作符中防止处理过多的数据（如limit）。
  - 输出可以是整个元组（NSM存储模式），或属性子集（DSM存储模式）。

# 2. 物化模型

```
out=[]
for t in child.Output():
   out.add(projection(t))
return out
```

1

```
out=[]
for t1 in left.output():
  buildHashTable(t1)
for t2 in right.output():
if Probe(t2) out.add(t1 ⋈ t2)
 return out
```

2

```
out=[]
for t in child.Output():
if evalPred(t) out.add(t)
reutrn out
```

所有元组

```
out=[]
for t in R:
out.add(t)
return out
```

3

```
out=[]
for t in S:
out.add(t)
return out
```

**Select R.id,S.cdate**
**From R join S**
**ON R.id=S.id**
**Where S.value>100**

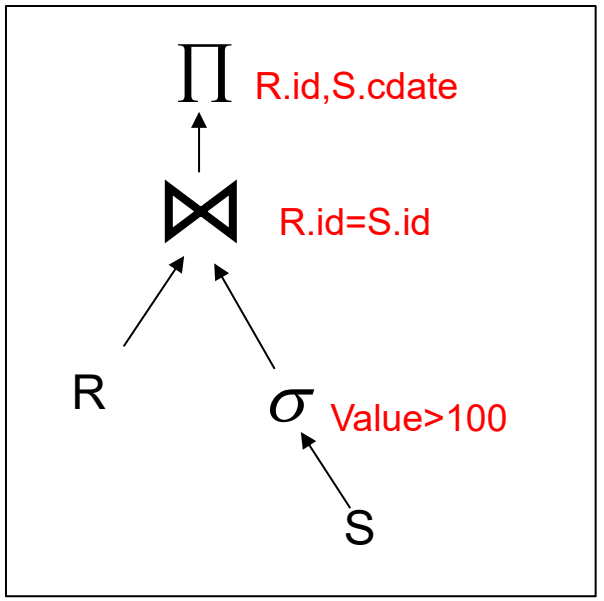

# 2. 物化模型

```
out=[]
for t in child.Output():
   out.add(projection(t))
return out
```

1

```
out=[]
for t1 in left.output():
  buildHashTable(t1)
for t2 in right.output():
if Probe(t2) out.add(t1   t2)
 return out
```

2

```
out=[]
for t in child.output():
if evalPred(t) out.add(t)
reutrn out
```

4

```
out=[]
for t in R:
out.add(t)
return out
```

3

```
out=[]
for t in S:
out.add(t)
return out
```

5

**Select R.id,S.cdate**
**From R join S**
**ON R.id=S.id**
**Where S.value>100**

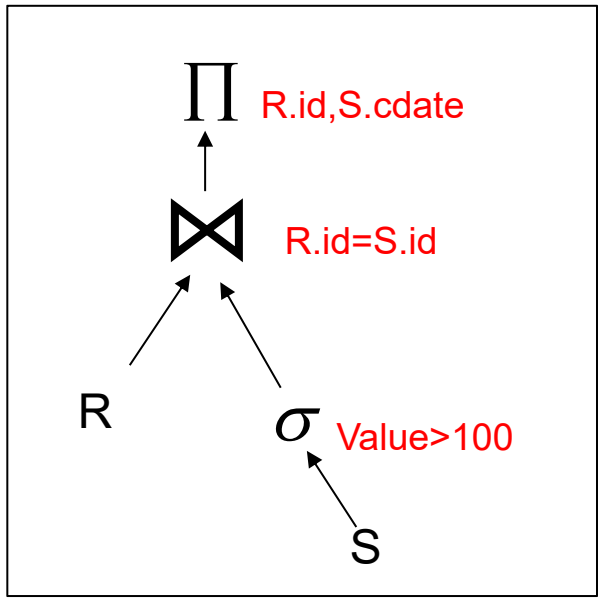

# 2. 物化模型

- 物化模型特点：
  - 适合OLTP，一次处理少量数据；
  - 相对火山模型，较少的函数调用，能减少不必要的执行、调度成本。
  - 不适合OLAP，AP查询可能产生较大的中间结果。

# 3. 向量/批处理模型

- 向量/批处理模型：
  - 是前两种模型的折中
  - 执行框架同火山模型
  - 不同之处是每次调用Next函数，返回的是一批（batch）元组而不是一个元组；操作符内部的循环每次也是一批一批元组地处理。
  - Batch的大小可以预先指定（比如硬件、查询的性质）。

# 3. 向量模型

```
out=[]
for t in child.Next():
  out.add(projection(t))
  if |out|>n: emit(out)
```

1

```
out=[]
for t1 in left.next():
 buildHashTable(t1)
for t2 in right.next():
 if Probe(t2) out.add(t1 ⋈ t2)
 if |out|>n: emit(out)
```

2

一批元组

```
out=[]
for t in R:
 out.add(t)
 if |out|>n:
    emit(out)
```

3

```
out=[]
for t in child.next():
 if evalPred(t) out.add(t)
 if |out|>n: emit(out)
```

4

```
out=[]
for t in S:
 out.add(t)
 if |out|>n: emit(out)
```

5

**Select R.id,S.cdate**
**From R join S**
**ON R.id=S.id**
**Where S.value>100**

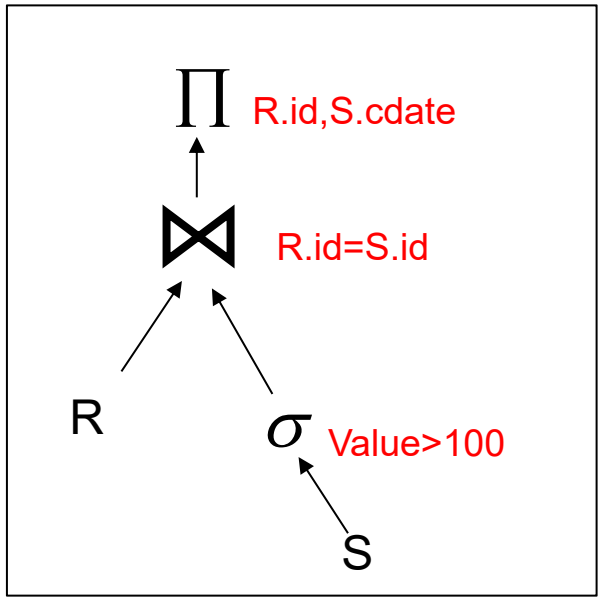

# 3. 向量模型

- 向量模型特点：
  - 介于火山模型和物化模型之间；
  - 适用于OLAP；
  - 允许用户使用向量化的SIMD指令处理批量元组。

*Presto、snowflake、SQLServer、Amazon Redshift等数据库支持这种处理模式。*

# 查询树处理的方向

- 自顶而下：从根节点开始不断的向子节点拉取数据，元组通过函数调用传递。
- 自底而上：从叶子点开始获取数据不断的向父节点推送数据。

# 9.1.3 数据存取

- 数据存取方法(access method)：

  访问存储在表(table)中的数据的方法。

  它并没有在关系代数中被定义。

```
Select R.id,S.cdate
From R join S
ON R.id=S.id
Where S.value>100
```

- 三种基本方法：
  - 顺序扫描
  - 索引扫描
  - 多索引扫描(位图扫描)

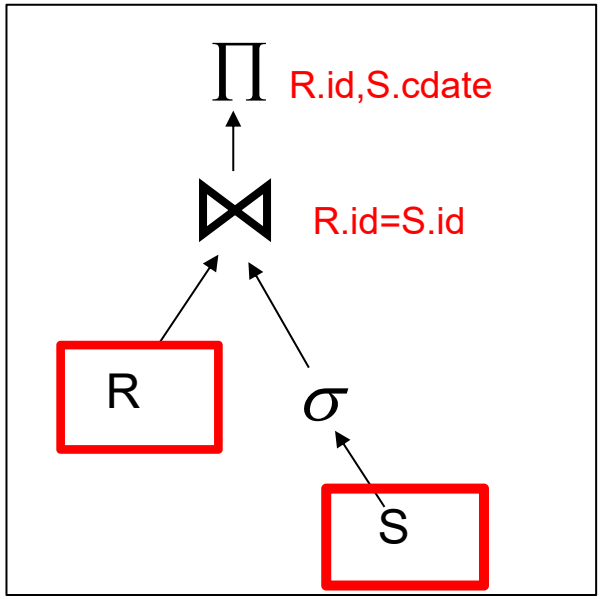

# 1. 顺序扫描

- 顺序扫描（Sequential Scan）：

  对于表的每一个Page

  - 加载到BufferPool中；
  - 对BufferPool的Page中符合条件的tuple依次进行处理。
  - DBMS内部维持一个游标指向上次访问的page/slot。

```
For Page in Table.Pages:
  For t in Page.tuples:
    If evalPred(t):
      Do Somthing
```

- 顺序扫描的优化：
  - Prefetching, buffer pool bypass, Parallization, Heap Clustering
  - Zone map
  - Late Materialization（迟物化）

# 1. 顺序扫描

## Zone Maps

- 预先计算一个页中的属性统计值（最大值，最小值，平均值），并存入zone map中；
- 在顺序扫描中根据zone map来决定是否读取该页。

**Select * from table**
Where val>600

原始数据

| Val |
|---|
| 100 |
| 200 |
| 300 |
| 400 |
| 400 |

Zone Maps

| type | Val |
|---|---|
| MIN | 100 |
| MAX | 400 |
| AVG | 280 |
| SUM | 1400 |
| count | 5 |

# 1. 顺序扫描

## Late Materialization

延迟缝合元组，直到查询计划的上层才缝合。

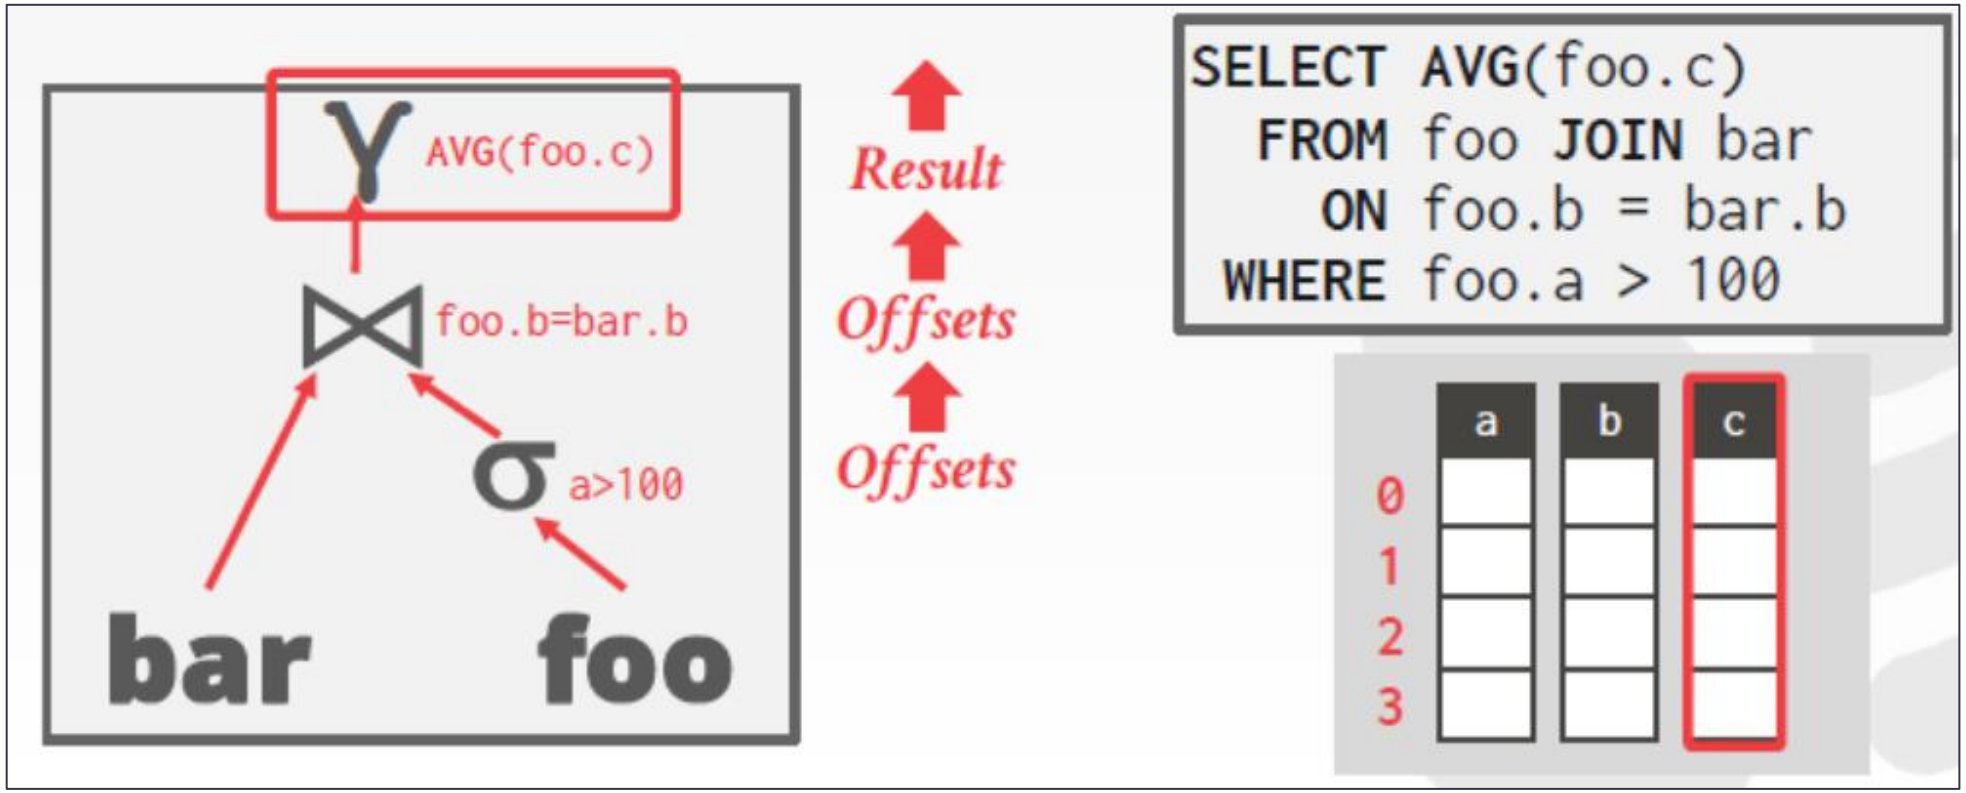

# 2. 索引扫描

- 索引扫描：通过索引来访问查询所需要的数据页。
- 例：假设students表包含100个元组和两个索引。
  - 索引 1: age
  - 索引 2: dept
  - 通常只用一个索引

数据的分布情况
决定了索引效果

```
Select * from students
Where age<30
And dept= ' CS'
And Country='US'
```

**场景1：**
**假设有99个学生年龄小于30，但是只有2个学生是CS系的，那么应该选择哪个属性索引呢?**

**场景2：**
**假设有99个学生是CS系的，但是只有2个学生年龄小于30，那么应该选择哪个属性索引呢?**

# 2. 索引扫描

## 多索引扫描

- 对每个索引进行扫描，获取那些指向满足单个条件的元组ID（或元组指针）；
- 根据谓词求取这些元组ID集合的并集或交集；
- 最后对于根据剩余的谓词（没有索引）过滤这些元组。

- Postgres 中Bitmap Scan

# 2. 索引扫描

- 多索引扫描举例：

  （假设在age和dept上有索引）

  ① 利用age的索引求age<30的元组指针集和（或元组ID集和）；

  ② 利用dept的索引求dept=’CS’的元组指针（或元组ID）；

  ③ 求两个集和的交集；

  ④ 根据交集检索数据并查看元组是否满足谓词Country=’US’。

```
Select * from students
Where age<30
And dept=’CS’
And Country=’US’
```

# 2. 索引扫描

- 多索引扫描（续）
  - 交（并）集的运算可以使用
  - 辅助数据库结构帮助我们计算如Hash Table, bitmaps, Bloom filters

**Select * from students**
**Where age<30**
**And dept= ’ CS’**
**And Country=’US’**

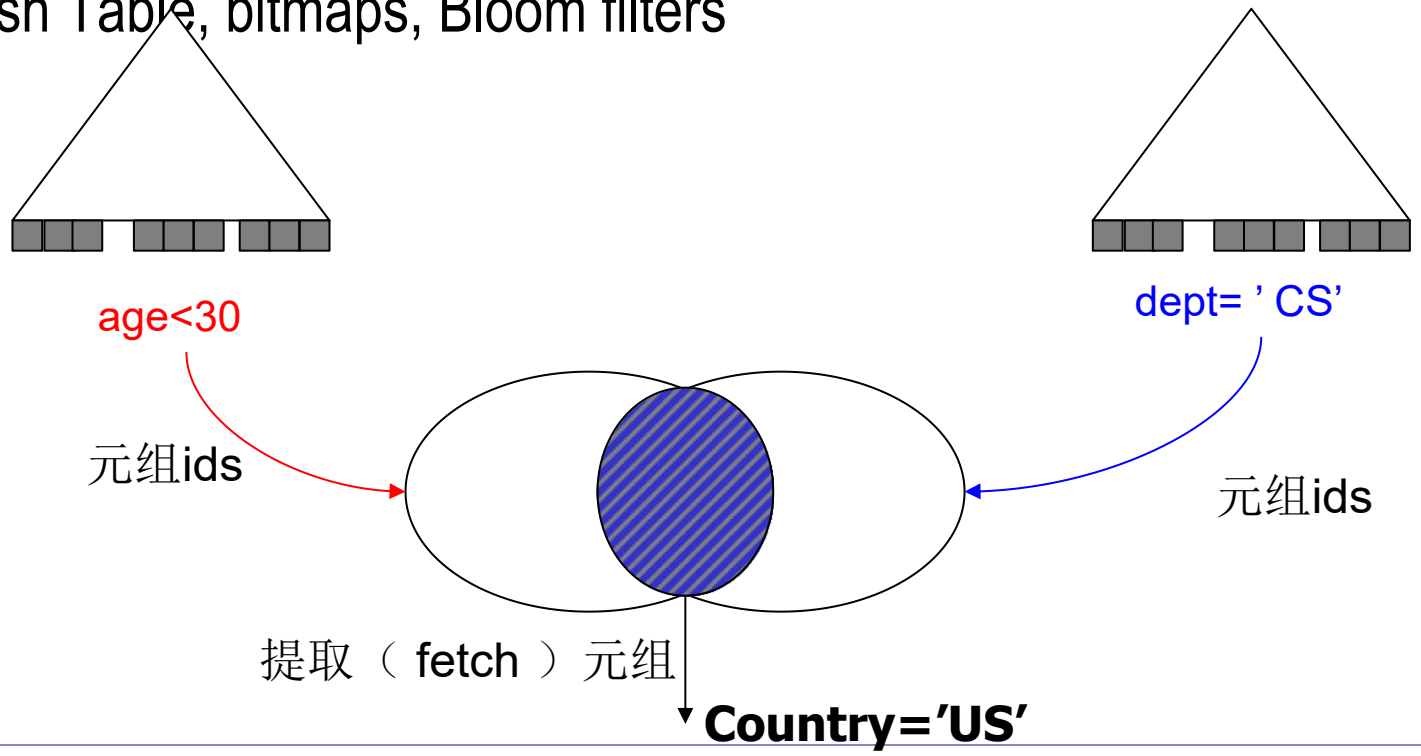

# 实现查询操作的算法示例

1.选择操作的实现

[例1] Select * from student where <条件表达式>；

考虑<条件表达式>的几种情况：

C1：无条件；

C2：Sno = '200215121'；

C3：Sage>20；

C4：Sdept = 'CS' AND Sage>20；

**选择操作典型实现方法：**

- **全表扫描（适合小表，不适合大表）；**
- **索引（或散列）扫描（适合选择条件中的属性上有索引）**

# 实现查询操作的算法示例

2.连接操作的实现

[例2] Select * from student , SC WHERE Student.Sno=SC.Sno;

**连接操作典型实现方法：**

**1. 嵌套循环方法(nested loop)**

**2. 排序-合并方法(sort-merge join 或merge join)**

**3. 索引连接(index join)方法**

**4. Hash Join方法**

外关系（outer relation）和 内关系（inner relation）

左
m个元组，占M页

右
n个元组，占N页

# 连接操作典型实现方法

1. 嵌套循环方法(nested loop)

- 对外层循环(Student)的每一个元组(s)，检索内层循环(SC)中的每一个元组(sc)；
- 检查这两个元组在连接属性(sno)上是否相等；
- 如果满足连接条件，则串接后作为结果输出，直到外层循环表中的元组处理完为止。

- 从算法上看，O(m*n)；
- 从磁盘IO看，从磁盘读m+m*n；
- 若外关系在内存中，只需要读m+n行
- 若外关系太大，采用**块嵌套循环连接方式**，M+M*N

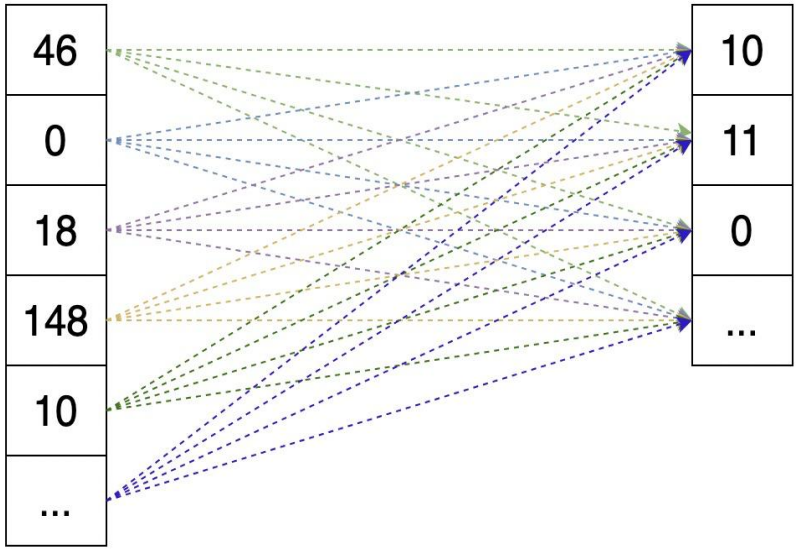

# 连接操作典型实现方法

2. 排序-合并方法(sort-merge join 或merge join)

- 适合连接的诸表已经排好序的情况。
- 步骤：
  - 如果连接的表没有排好序，先对Student表和SC表按连接属性Sno排序；
  - 取Student表中第一个Sno，依次扫描SC表中具有相同Sno的元组；

    ……
  - 重复上述步骤直到Student 表扫描完。

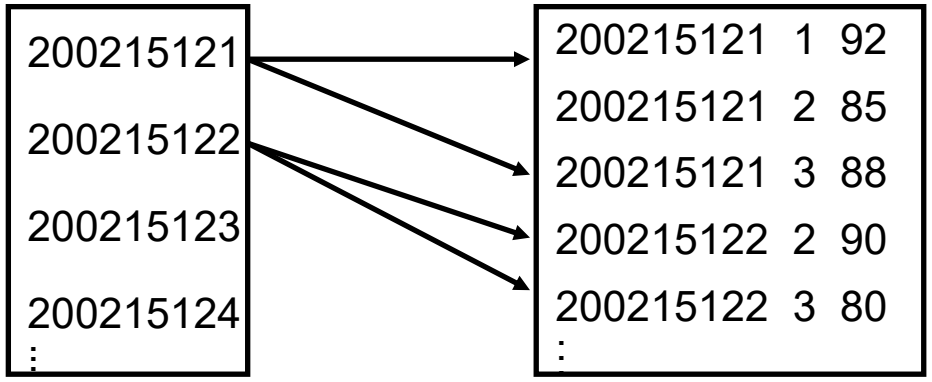


Student表和SC表都只要扫描一遍

若左右表均有序，O(m+n)
若还需要排序，排序成本：
O(m*Log(m) + n*Log(n))

# 连接操作典型实现方法

## 3. 索引连接(index join)方法

- 步骤：

① 在内关系（SC表）上建立连接属性Sno的索引(如果原来没有)；

② 对外关系（S）中每个元组，由Sno值通过SC的索引查找相应的SC元组

③ 把这些SC元组和Student元组连接起来；

循环执行②③，直到Student表中的元组处理完为止。

假设索引查找带来的I/O开销为C，
则总的I/O开销为：M+(m×C)

**如果两个关系上均有索引时， 一般把元组较少的关系作外关系时效果较好。**

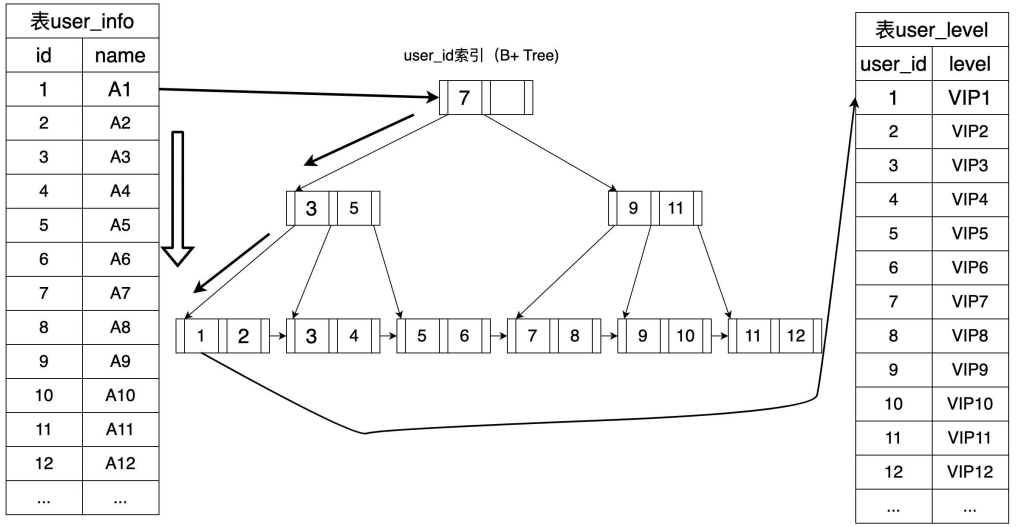

# 连接操作典型实现方法

## 4. Hash Join方法

把连接属性作为hash码，用同一个hash函数把R和S中的元组散列到同一个hash文件中。

- 步骤：
  - 划分阶段(partitioning phase)
  - 试探阶段(probing phase)：

  也称为连接阶段(join phase)

设内关系被划分成 X 个散列桶，
创建散列表的成本(m) +散列函数的计算开销*n + (m/X) * n

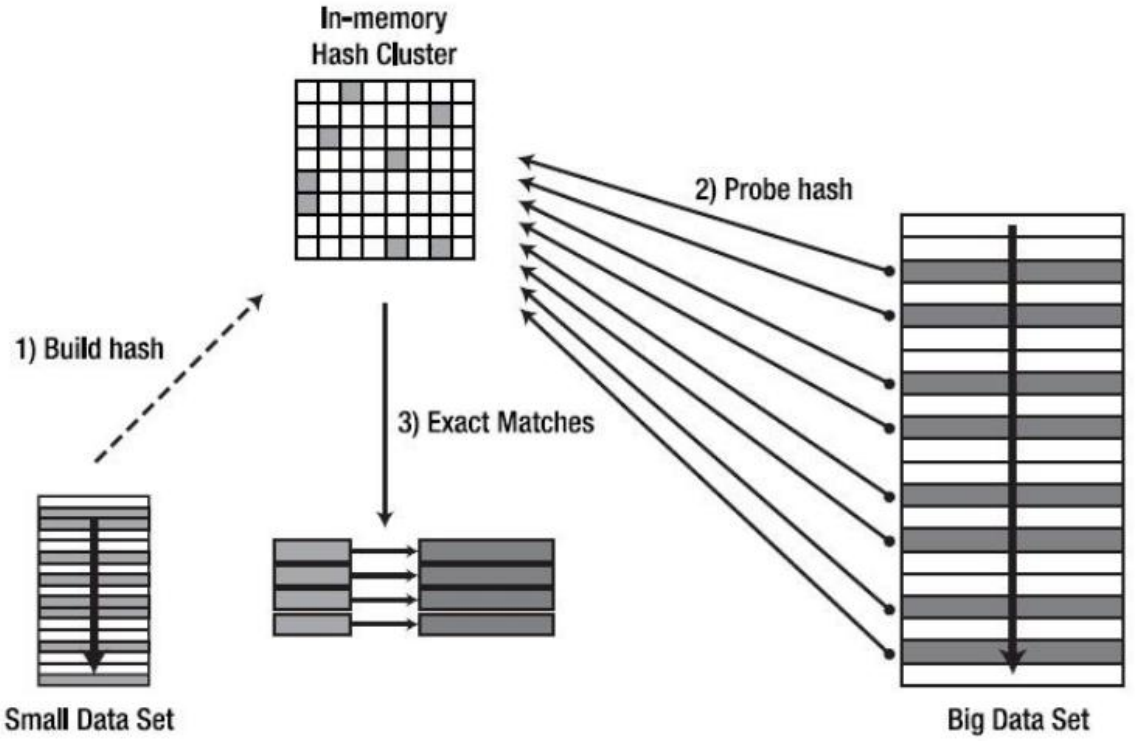


Figure 12-1. *Optimal hash join*


33

# 连接算法的选择

(1) 空闲内存：内存不够则无法使用内存中的Hash连接。

(2) 两个数据集的大小：

若一个大表连接一个很小的表，则嵌套循环连接就比散列连接快；

若两个表都非常大，则嵌套循环连接的CPU成本就很高。

(3) 是否有索引：单一有，选索引连接；

若连接属性上有两个B+树索引的话，合并连接是好选择。

(4) 关系是否已经排序：有则选用合并连接。

(5) 结果是否需要排序：即使参与连接的是未排序的数据集，也可考虑使用成本较高的合并连接。

(6) 连接的类型：是等值连接？还是内连接？外连接？笛卡尔积？或者自连接？有些连接算法在某些情况下是不适用的。

(7) 数据的分布：若连接条件的数据是倾斜的，Hash连接不是好选择。

(8) 多表连接：连接顺序的选择很重要。